

Kausale Inferenz

Kapitel 6: Inverse Probability Weighting

Sommersemester 2017

Version: 24. Juli 2017

Michael Schomaker

University of Cape Town, CIDER, South Africa

Ludwig-Maximilians-Universität München, Institut für Statistik



- Sei π_i die Auswahlwahrscheinlichkeit für das i -te Individuum in die Stichprobe aufgenommen zu werden
- Sei N die Anzahl der Beobachtungen in der Grundgesamtheit, n die Größe der Stichprobe
- Bei einer einfachen Zufallsauswahl ist $\pi_i = n/N$
- Sei y_1, \dots, y_n eine Stichprobe bezüglich der Variable Y

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Horvitz-Thompson-Schätzer [1]

Der Horvitz-Thompson Schätzer für das arithmetische Mittel in der Grundgesamtheit ist

$$\hat{Y}_{\text{HT}} = \frac{1}{N} \sum_{i=1}^n \frac{y_i}{\pi_i}$$



IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Beispiel:

4 Individuen mit $Y_1 = 10$, $Y_2 = 20$, $Y_3 = 80$, $Y_4 = 90$

Stichprobe vom Umfang $n = 2$

Y_4 habe höhere Auswahlwahrscheinlichkeit:

$\pi_{1,2,3} < \pi_4$ (Urne mit 5 Kugeln: 1,2,3,4,4)

Gezogene Individuen		\bar{y}	Wahrscheinlichkeit
1	2	15	$1/10 = 1/5 \cdot 1/4 + 1/5 \cdot 1/4$
1	3	45	$1/10$
1	4	50	$7/30 = 1/5 \cdot 2/4 + 2/5 \cdot 1/3$
2	3	50	$1/10$
2	4	55	$7/30$
3	4	85	$7/30$



Beispiel:

Verteilung des arithmetischen Mittels:

\bar{y}	15	45	50	55	85
$P(\bar{y})$	1/10	1/10	1/3	7/30	7/30

Auswahlwahrscheinlichkeiten:

i	1	2	3	4
π_i	13/30	13/30	13/30	21/30

Kommen Individuen 1 und 2 in die Stichprobe:

$$\bar{y} = 15$$

$$\hat{Y}_{HT} = \frac{1}{N} \sum_{i=1}^n \frac{y_i}{\pi_i} = \frac{1}{4} \left(\frac{10}{13/30} + \frac{20}{13/30} \right) = 17.31$$

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Beispiel: Verteilung des Horvitz-Thompson-Schätzers:

\hat{Y}_{HT}	17.31	37.91	43.68	51.92	57.69	78.30
$P(\hat{Y}_{HT})$	1/10	7/30	7/30	1/10	1/10	7/30

Das heißt:

$$E(\hat{Y}_{HT}) = \left(17.31 \cdot \frac{1}{10} + \dots + 78.30 \cdot \frac{7}{30} \right) = 50$$

$$E(\bar{y}) = \left(15 \cdot \frac{1}{10} + \dots + 85 \cdot \frac{7}{30} \right) = 55.33$$

Horvitz-Thompson-Schätzer

IPTW

- Stabilisierte Gewichte
- Marginale strukturelle Modelle
- Progressive Trunkierung
- Positivität
- Konfidenzintervalle
- Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Sei I_i der Indikator, der angibt, ob das i -te Individuum in die Stichprobe gezogen wird.

$$\hat{Y}_{\text{HT}} = \frac{1}{N} \sum_{i=1}^n \frac{y_i}{\pi_i} = \frac{1}{N} \sum_{i=1}^N \frac{Y_i I_i}{\pi_i}$$

I ist eine Bernoulli-Variable mit $E(I_i) = P(I_i = 1) = \pi_i$. Damit können wir schreiben:

$$E(\hat{Y}_{\text{HT}}) = \frac{1}{N} \sum_{i=1}^N \frac{Y_i E(I_i)}{\pi_i} = \bar{Y}$$

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW


Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Idee: Kreiere Pseudo-Population, bei der Confounding aufgehoben wird



- Damit wird aus Assoziation Kausalität
- Verwende hierzu die Gewichte

$$w = 1/\pi = 1/p = \frac{1}{f(A|L)}$$

bzw. für diskretes A

$$w = 1/\pi = 1/p = \frac{1}{P(A = a|L)}$$



Horvitz-Thompson-Schätzer

IPTW-Schätzer (auf Basis des Horvitz-Thomson-Schätzers)

Unter den Annahmen der Positivität, bedingten Austauschbarkeit und Konsistenz gilt

$$E(Y^a) = E\left(\frac{Y \cdot I(A = a)}{p}\right)$$

Ein Schätzer für den Average Treatment Effect ist damit

$$\hat{\psi}_{\text{ATE}} = \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 1)}{P(A_i = 1|L_i)} - \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 0)}{P(A_i = 0|L_i)}$$

IPTW

- Stabilisierte Gewichte
- Marginale strukturelle Modelle
- Progressive Trunkierung
- Positivität
- Konfidenzintervalle
- Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- 1 Schätze den Mechanismus der Behandlungszuweisung:
 $P(A = 1|L)$

(z.B. logistische Regression)

- 2 Schätze damit p_i :

- Für diejenigen, die tatsächlich behandelt wurden ($A_i = 1$):
verwende einfach $\hat{P}(A = 1|L = l_i)$
- Für diejenigen, die nicht behandelt wurden ($A_i = 0$):
verwende $1 - \hat{P}(A = 1|L = l_i)$

- 3 Jedes Individuum erhält das Gewicht $\hat{w}_i = 1/\hat{p}_i$

- 4 Schätze dann z.B.

$$E(Y^1) = \frac{1}{n} \sum_{i=1}^n [y_i \times I(A_i = 1) \times w_i]$$

(oder marginales strukturelles Modell, siehe unten)

Beispiel (aus Kapitel 5)

i	L	A	Y	p_i	w_i
1	0	0	0	?	?
2	0	0	1	?	?
3	0	0	0	?	?
4	0	1	0	?	?
5	0	1	1	?	?
6	0	1	1	?	?
7	0	0	0	?	?
8	1	0	0	?	?
9	1	1	0	?	?
10	1	1	1	?	?
11	1	0	1	?	?
12	1	0	1	?	?



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

$$\begin{aligned} p_{11} &= P(A = 1|L = 1) &= \frac{2}{5} \\ p_{01} &= P(A = 0|L = 1) &= \frac{3}{5} \\ p_{10} &= P(A = 1|L = 0) &= \frac{3}{7} \\ p_{00} &= P(A = 0|L = 0) &= \frac{4}{7} \end{aligned}$$

und damit

$$\begin{aligned} w_{11} &= 1/P(A = 1|L = 1) &= \frac{5}{2} \\ w_{01} &= 1/P(A = 0|L = 1) &= \frac{5}{3} \\ w_{10} &= 1/P(A = 1|L = 0) &= \frac{7}{3} \\ w_{00} &= 1/P(A = 0|L = 0) &= \frac{7}{4} \end{aligned}$$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

i	L	A	Y	p_i	w_i
1	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$
2	0	0	1	$\frac{4}{7}$	$\frac{7}{4}$
3	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$
4	0	1	0	$\frac{3}{7}$	$\frac{7}{3}$
5	0	1	1	$\frac{3}{7}$	$\frac{7}{3}$
6	0	1	1	$\frac{3}{7}$	$\frac{7}{3}$
7	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$
8	1	0	0	$\frac{3}{5}$	$\frac{5}{3}$
9	1	1	0	$\frac{2}{5}$	$\frac{5}{2}$
10	1	1	1	$\frac{2}{5}$	$\frac{5}{2}$
11	1	0	1	$\frac{3}{5}$	$\frac{5}{3}$
12	1	0	1	$\frac{3}{5}$	$\frac{5}{3}$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

$$\begin{aligned} E(Y^1) &= \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 1)}{P(A_i = 1|L_i)} \\ &= \frac{1}{12} \left(\frac{7}{3} \cdot 0 + \frac{7}{3} \cdot 1 + \frac{7}{3} \cdot 1 + \frac{5}{2} \cdot 0 + \frac{5}{2} \cdot 1 \right) \\ &= \frac{1}{12} \left(\frac{28}{6} + \frac{15}{6} \right) = 0.5972 \end{aligned}$$

$$\begin{aligned} E(Y^0) &= \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 0)}{P(A_i = 0|L_i)} \\ &= \frac{1}{12} \left(\frac{7}{4} \cdot 0 + \frac{7}{4} \cdot 1 + \frac{7}{4} \cdot 0 + \frac{7}{4} \cdot 0 + \frac{5}{3} \cdot 0 + \frac{5}{3} \cdot 1 + \frac{5}{3} \cdot 1 \right) \\ &= \frac{1}{12} \left(\frac{7}{4} + \frac{10}{3} \right) = 0.4236 \end{aligned}$$

$$\hat{\psi}_{ATE} = 0.5972 - 0.4236 = 0.1736$$

→ korrektes Ergebnis!

Gleiches Ergebnis bei Verwendung logistischer Regression

```
m.w      <- glm(A~L, family=binomial)
weight    <- 1/predict(m.w, type="response")
weight[A==0] <- 1/(1-predict(m.w, type="response") [A==0])
```

```
mean(Y*(A==1)*weight)
```

```
mean(Y*(A==0)*weight)
```

```
> weight
```

1	2	3	4	5	6	7	8	9	10	11	12
1.75	1.75	1.75	2.33	2.33	2.33	1.75	1.67	2.50	2.50	1.67	1.67

```
> mean(Y*(A==1)*weight)
```

```
[1] 0.5966667
```

```
> mean(Y*(A==0)*weight)
```

```
[1] 0.4241667
```



IPTW

- Stabilisierte Gewichte
- Marginale strukturelle Modelle
- Progressive Trunkierung
- Positivität
- Konfidenzintervalle
- Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Der IPTW-Schätzer schätzt $E(Y^a)$



IPTW

- Stabilisierte Gewichte
- Marginale strukturelle Modelle
- Progressive Trunkierung
- Positivität
- Konfidenzintervalle
- Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Für den diskreten Fall:

$$\begin{aligned} E_Y \left(\frac{Y \cdot I(A=a)}{p} \right) &\stackrel{\text{Kons.}}{=} E_{Y^a} \left(\frac{Y^a \cdot I(A=a)}{p} \right) \\ &\stackrel{\text{BE}}{=} E_L \left\{ E_{Y^a|L} \left(\frac{Y^a \cdot I(A=a)}{P(A=a|L)} \right) | L \right\} \\ &\stackrel{\text{Aust.}}{=} E_L \left\{ \underbrace{E_{Y^a|L} \left(\frac{I(A=a)}{P(A=a|L)} | L \right)}_{=1} \cdot E_{Y^a|L}(Y^a | L) \right\} \\ &= E_L \{ E_{Y^a|L}(Y^a | L) \} \\ &\stackrel{\text{BE}}{=} E(Y^a) \end{aligned}$$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Die Ergebnisse eines marginalen strukturellen Modells ändern sich nicht wenn statt der Gewichte

$$w = \frac{1}{P(A = a|L)}$$

die Gewichte

$$w = \frac{c}{P(A = a|L)}, \quad 0 < c \leq 1$$

verwendet werden [2].

- Stabilisierte Gewichte:

$$w_s = \frac{P(A = a)}{P(A = a|L)}$$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Einzelne nichtstabilisierte Gewichte können sehr hoch sein, stabilisierte Gewichte reduzieren die Spannweite der Gewichte
- Wichtig um Schätzgrenzen einzuhalten, z.B. dass $\hat{P}(Y = 1) \leq 1$
- Reduzierung der Breite der Konfidenzintervalle



```
> m.w          <- glm(A~L,family=binomial)
> weight       <- 1/predict(m.w, type="response")
> weight[A==0] <- 1/(1-predict(m.w, type="response") [A==0])
>
> m.w2 <- glm(A~1,family=binomial)
> weight2      <- 1/predict(m.w2, type="response")
> weight2[A==0] <- 1/(1-predict(m.w2, type="response") [A==0])
>
> sweight <- weight/weight2
>
> summary(weight)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 1.667  1.729  1.750   2.000  2.333   2.500
> summary(sweight)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.9722  0.9722  0.9965  1.0000  1.0210  1.0420
```

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

$$\begin{aligned}
 E(Y^1) &\stackrel{\text{Def.}}{=} \frac{1}{n} \sum_{i=1}^n y_i \cdot I(A_i = 1) \cdot w_i \\
 &\stackrel{\text{Erw.}}{=} \frac{1}{n} \sum_{i=1}^n y_i \cdot I(A_i = 1) \cdot \frac{1}{P(A_i = 1|L)} \cdot \frac{P(A_i = 1)}{P(A_i = 1)} \\
 &= \frac{1}{n} \sum_{i=1}^n y_i \cdot I(A_i = 1) \cdot \underbrace{\frac{P(A_i = 1)}{P(A_i = 1|L)}}_{w_{S,i}} \cdot \frac{1}{P(A_i = 1)} \\
 &= \frac{1}{12} \left(\frac{0 \cdot \frac{5/12}{3/7}}{5/12} + \frac{1 \cdot \frac{5/12}{3/7}}{5/12} + \frac{1 \cdot \frac{5/12}{3/7}}{5/12} + \frac{0 \cdot \frac{5/12}{2/5}}{5/12} + \frac{1 \cdot \frac{5/12}{2/5}}{5/12} \right) \\
 &= \frac{1}{12} \left(\frac{7}{3} + \frac{7}{3} + \frac{5}{2} \right) \\
 &= 0.5972
 \end{aligned}$$

Aber:

$$\frac{1}{n} \sum_{i=1}^n y_i \cdot I(A_i = 1) w_{S,i} = 0.5972 \cdot \frac{5}{12} = 0.249$$



Das heisst:

$$\psi_{ATE} = \hat{\psi}_{1, w_s} \cdot \frac{1}{P(A=1)} - \hat{\psi}_{0, w_s} \cdot \frac{1}{P(A=0)}$$

Besser:

- verwende Gewichte in marginalem strukturellen Modell
- für den ATE: lineares gewichtetes Modell

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Gegeben sei ein lineares strukturelles Modell

$$E(Y^a) = \beta_0 + \beta_1 A$$

Dann ist

$$E(Y^a) = \beta_0 \quad \text{für } A = 0$$

$$E(Y^a) = \beta_0 + \beta_1 \quad \text{für } A = 1$$

Das heisst:

$$\psi_{ATE} = \beta_1$$

In der durch Gewichtung entstandenen Pseudopopulation ist
Assoziation = Kausalität und das gewichtete lineare Modell

$$E(Y|A) = \beta_0 + \beta_1 A$$

liefert den ATE über β_1 .

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



...liefert korrektes Ergebnis ($\hat{\psi} = 0.1736$) für normale und stabilisierte Gewichte

```
> lm(Y~A, weights=weight)
```

Call:

```
lm(formula = Y ~ A, weights = weight)
```

Coefficients:

(Intercept)	A
0.4236	0.1736

```
> lm(Y~A, weights=sweight)
```

Call:

```
lm(formula = Y ~ A, weights = sweight)
```

Coefficients:

(Intercept)	A
0.4236	0.1736

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Warum nicht den [causal] odds ratio berechnen?



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Mit den Werten von oben erhalten wir:

$$\begin{aligned}\psi_{\text{OR}} &= \frac{P(Y^1 = 1)/P(Y^1 = 0)}{P(Y^0 = 1)/P(Y^0 = 0)} \\ &= \frac{0.59722/(1 - 0.59722)}{0.42361/(1 - 0.42361)} = 2.02\end{aligned}$$

Ein gewichtetes logistisches Modell in *R* liefert:

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.308	0.765	-0.40	0.69
A	0.702	1.190	0.59	0.56

Korrekt, da $\exp(0.702) = 2.02!$



- Wir haben ein lineares Modell

$$\mathcal{M}(A, \beta) : E(Y|A) = \beta_0 + \beta_1 A$$

- Mögliche Schätzung über kleinste Quadrate:

$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 a_i)^2$$

- z.B. Schätzung für β_1 über partielle Ableitung und Nullsetzen:

$$\sum_{i=1}^n \frac{\partial}{\partial \beta_1} (y_i - \beta_0 - \beta_1 a_i)^2 = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 a_i) a_i.$$

also

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 a_i) a_i = 0$$

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

■ Etwas allgemeiner:

$$0 = \frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial \beta} \mathcal{M}(\mathbf{a}_i, \beta) (y_i - \mathcal{M}(\mathbf{a}_i, \beta))$$

■ Der IPTW-Schätzer ist die Lösung der Schätzgleichung

$$0 = \frac{1}{n} \sum_{i=1}^n \frac{g(A)}{h(A|L)} \frac{\partial}{\partial \beta} \mathcal{M}(\mathbf{a}_i, \beta) (y_i - \mathcal{M}(\mathbf{a}_i, \beta))$$

...und deswegen können wir gewichtete Regression verwenden...



- Gewichtungsprinzip kann auch in kausaler Inferenz verwendet werden
- Wir erzeugen eine Pseudopopulation der es kein Confounding gibt und damit Assoziation Kausalität ist
- Hierzu müssen wir ein Modell für $P(A|L)$ schätzen (und ggf. auch $P(A)$ berechnen)
- Ein gewichtetes lineares Modell liefert oft ψ_{ATE} und ein gewichtetes logistisches Modell ψ_{OR}
- Am einfachsten: gewichtete Regression $\stackrel{\text{oft}}{=}$ marginales strukturelles Modell

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



- Einzelne Gewichte sollten nicht zu hoch sein
- Das arithmetische Mittel der stabilisierten Gewichte sollte etwa 1 sein

Beispiel: Krebsdaten

	Min	1st Qu.	Median	Mean	3rd Qu.	Max.
w	1	1.3	1.6	2.0	2.1	137.0
w_s	0.5	0.6	0.8	1.0	1.1	50.2

- arithmetisches Mittel von 1 (gut)
- aber hohe Gewichte (siehe Positivität)

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Was, wenn das arithmetische Mittel nicht 1 ist?



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Progressive Trunkierung wird oft verwendet
- Vorgehen:
 - 1 Bestimme das α und $1 - \alpha$ -Quantil ($q_\alpha; q_{1-\alpha}$) der Gewichte
 - 2 Gewichte, die kleiner als q_α sind werden trunkiert und durch das entsprechende Quantil ersetzt
 - 3 Gewichte, die größer als $q_{1-\alpha}$ sind werden trunkiert und durch das entsprechende Quantil ersetzt
- → Reduzierung der Variabilität auf Kosten von Bias!



Variation der Effektschätzung bezüglich der Trunkierung

Truncation percentiles	Estimated weights for the outcome Death or LTF		Estimates of effect of club on Death or LTF	
	Mean (SD)	Minimum/ maximum	Estimate	Standard Error
0,100	1.06 (0.54)	0.01/11.12	0.43	0.16
1,99	1.09 (0.42)	0.05/3.02	0.44	0.14
5,95	1.01 (0.07)	0.92/1.22	0.44	0.13
10,90	1.01 (0.03)	0.97/1.07	0.45	0.13
25,75	1.00 (0.01)	0.99/1.01	0.46	0.13

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



- Konsistenz des IPTW-Schätzers hängt von der Konsistenz der Schätzung von $P(A|L)$ ab
- Trunkierung führt dazu, dass der Schätzer nicht mehr konsistent ist
- Trunkierung kann gut sein, muss es aber nicht
- Der perfekte “Bias-Variance-Tradeoff” ist schwer zu finden
- Im Zweifel besser eine alternative Methode verwenden (z.B. Standardisierung)

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

	Bias	Var	MSE
G-COMP			
None	0.007	0.009	0.009
[0.025,0.975]	0.007	0.009	0.009
[0.05,0.95]	0.007	0.009	0.009
[0.1,0.9]	0.007	0.009	0.009
IPTW			
None	0.544	0.693	0.989
[0.025,0.975]	1.080	0.090	1.257
[0.05,0.95]	1.437	0.059	2.123
[0.1,0.9]	1.935	0.043	3.787



Beispiel: Krebsdaten

Einige Personen haben sehr hohe Gewichte (> 30)

```
> Odat1[sweight>30,]
      ID    w1      w2      w3      w4 a y
1152 1152  old      2_middle other stage 4 0 1
1586 1586  old 3_lower middle other stage 4 0 1
1716 1716 young 2_middle other stage 4 0 1
4314 4314 young 3_lower middle alzheimer stage 4 0 1
```

Dies scheinen Leute zu sein, die nicht behandelt wurden ($a = 0$), trotz fortgeschrittener Erkrankung (stage 4 & Begleiterkrankungen)

Gibt es Positivitätsprobleme?

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Antwort: ja



, , = other, = stage 4

	1_upper middle	2_middle	3_lower middle	4_working	5_non-working
0		0	2	1	0
1		3	25	88	34
					22

z.B.: 1(!) Person repräsentiert die komplette Schicht “ $a=0$, $W_2 = 4$, $W_3 = \text{other}$, $W_4 = 4$ ” in den Daten und bekommt ein hohes Gewicht

z.B: Keiner wurde nicht behandelt in der Schicht “ $W_2 = 4$, $W_3 = \text{other}$, $W_4 = 5$ ”

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Große Gewichte können auf Positivitätsprobleme zurückzuführen sein
- Gibt es keine großen Gewichte, heißt das nicht automatisch, dass es keine Positivitätsprobleme gibt
- Der IPTW-Schätzer ist sehr sensibel gegenüber Positivitätsverletzung
- Das ist ein Argument dafür andere Schätzer zu verwenden
- Wird ein marginales strukturelles Modell über gewichtete Regression geschätzt, so kann das Modell in “leere Regionen” extrapolieren...
- ...dies funktioniert nur, wenn das marginale Modell korrekt spezifiziert ist (andere Methoden können generell besser extrapolieren)



Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Trunkierung; eher als Sensitivitätsanalyse um zu sehen, ob die Effektschätzung stabil ist, anstatt als Lösung
- Analyse von Gewichten:
 - um zu sehen, ob über verbesserte Modellspezifizierung (für $P(A|L)$) sich das aritmetische Mittel verbessert
 - und hohe Gewichte reduziert werden können
- Veränderung der Fragestellung, z.B. Restriktion auf eine Untermenge der Daten
- Verwendung eines besseren Schätzers(!)



Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

1 Verwende robusten Varianzschätzer über GEE's (z.B. `geeglm()` in *R*)

- Gewichtung macht aus einer Beobachtung mehrere Beobachtungen, deswegen ist normaler OLS-Schätzer nicht passend
- fast immer verwendet
- Problem: Dieser Standardfehler ist generell konservativ, Konfidenzintervalle sind zu groß [5]
- Gewichte sind nicht fest, sondern werden geschätzt

2 Bootstrapping

- aufwändiger, aber häufig besser
- Modellselektion (oder allgemeiner: machine learning) während des Bootstraps nicht optimal



Beispiel: Krebsdaten

```
msm_cancer <- geeglm(y~a, weights=sweight, data=Odat, id=c(seq(1:5000)))
```

Schätzer	S.E.
Naive	0.0125
Robust	0.0339
Bootstrapping	0.0310

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Hängt die Fehlwahrscheinlichkeit von beobachtbaren (bzw. unbeobachtbaren) Variablen ab, so ist in der Regel¹ die Schätzung auf Basis der vollständigen Fälle verzerrt

- Idee: interveniere auf die fehlenden Daten und schätze

$$Y^{A=a, C=0}$$

wobei $C_i = 0$ für einen vollständigen Fall steht

- C kann allgemein für fehlende Werte stehen, für fehlende Werte von Y , oder für zensierte Daten bei Longitudinaldaten
- wir betrachten den allgemeinen Fall bei Querschnittsdaten

¹ Beispiel für eine Ausnahme: Regressionsparameter, wenn Fehlwahrscheinlichkeit nicht von der Zielgröße abhängt



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

- Erzeuge eine Pseudopopulation, mit derselben Größe wie die ursprüngliche Population ohne fehlende Daten, und in der es kein Confounding gibt
- Die Wahrscheinlichkeit für eine vollständige Beobachtung ist

$$P(C = 0|A, L, Y)$$

und kann über logistische Regression oder Stratifizierung geschätzt werden

- Multipliziere diese inverse (stabilisierte) Wahrscheinlichkeit an das (stabilisierte) Gewicht bezüglich der Behandlungszuweisung



IPCTW-Schätzer

Unter den Annahmen der Positivität, bedingten Austauschbarkeit und Konsistenz gilt

$$E(Y^{a,C=0}) = E\left(\frac{Y \cdot I(A = a, C = 0)}{P(A = a|L) \times P(C = 0|A, L, Y)}\right)$$

Ein Schätzer für den Average Treatment Effect ist damit

$$\hat{\psi}_{ATE} = \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 1, C_i = 0)}{P(A_i = 1|L_i) \cdot P(C_i = 0|A_i, L_i, Y_i)} - \frac{1}{n} \sum_{i=1}^n \frac{y_i \cdot I(A_i = 0, C_i = 0)}{P(A_i = 0|L_i) \cdot P(C_i = 0|A_i, L_i, Y_i)}$$

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



IPCTW-Schätzer (II)

Unter Verwendung von

$$w_i^{aC} = \left\{ \underbrace{P(A_i = a | L_i)}_{w_i^a} \cdot \underbrace{P(C_i = 0 | A_i, L_i, Y_i)}_{w_i^C} \right\}^{-1}$$

lässt sich $E(Y^{a,C=0})$ über

$$\begin{aligned} \hat{\psi}_{ATE} &= \frac{1}{n} \sum_{i=1}^n w_i^{1C} \cdot y_i \cdot I(A_i = 1, C_i = 0) - \\ &\quad \frac{1}{n} \sum_{i=1}^n w_i^{0C} \cdot y_i \cdot I(A_i = 0, C_i = 0) \end{aligned}$$

schätzen.

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



i	L	A	Y	C	p_i^a	w_i^a	p_i^C	w_i^C	w_i^{aC}
1	0	0	0	1	$\frac{4}{7}$	$\frac{7}{4}$?	?	?
2	0	0	1	0	$\frac{4}{7}$	$\frac{7}{4}$?	?	?
3	0	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$?	?	?
4	0	1	0	0	$\frac{3}{7}$	$\frac{7}{3}$?	?	?
5	0	1	1	0	$\frac{3}{7}$	$\frac{7}{3}$?	?	?
6	0	1	1	0	$\frac{3}{7}$	$\frac{7}{3}$?	?	?
7	0	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$?	?	?
8	1	0	0	0	$\frac{3}{5}$	$\frac{5}{3}$?	?	?
9	1	1	0	0	$\frac{2}{5}$	$\frac{5}{2}$?	?	?
10	1	1	1	0	$\frac{2}{5}$	$\frac{5}{2}$?	?	?
11	1	0	1	0	$\frac{3}{5}$	$\frac{5}{3}$?	?	?
12	1	0	1	1	$\frac{3}{5}$	$\frac{5}{3}$?	?	?

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

$$\begin{aligned}P(C = 1|L = 1, A = 1, Y = 1) &= 0 \\P(C = 1|L = 1, A = 0, Y = 1) &= 1/2 \\P(C = 1|L = 0, A = 1, Y = 1) &= 0 \\P(C = 1|L = 0, A = 0, Y = 1) &= 0 \\\\P(C = 1|L = 1, A = 1, Y = 0) &= 0 \\P(C = 1|L = 1, A = 0, Y = 0) &= 0 \\P(C = 1|L = 0, A = 1, Y = 0) &= 0 \\P(C = 1|L = 0, A = 0, Y = 0) &= 1/3 \\\\P(C = 0|L = 1, A = 1, Y = 1) &= 1 \\P(C = 0|L = 1, A = 0, Y = 1) &= 1/2 \\P(C = 0|L = 0, A = 1, Y = 1) &= 1 \\P(C = 0|L = 0, A = 0, Y = 1) &= 1 \\\\P(C = 0|L = 1, A = 1, Y = 0) &= 1 \\P(C = 0|L = 1, A = 0, Y = 0) &= 1 \\P(C = 0|L = 0, A = 1, Y = 0) &= 1 \\P(C = 0|L = 0, A = 0, Y = 0) &= 2/3\end{aligned}$$



i	L	A	Y	C	p_i^a	w_i^a	p_i^C	w_i^C	w_i^{aC}
1	0	0	0	1	$\frac{4}{7}$	$\frac{7}{4}$	0	0	0
2	0	0	1	0	$\frac{4}{7}$	$\frac{7}{4}$	1	1	$\frac{7}{4}$
3	0	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$	$\frac{2}{3}$	$\frac{3}{2}$	$\frac{21}{8}$
4	0	1	0	0	$\frac{3}{7}$	$\frac{7}{3}$	1	1	$\frac{7}{3}$
5	0	1	1	0	$\frac{3}{7}$	$\frac{7}{3}$	1	1	$\frac{7}{3}$
6	0	1	1	0	$\frac{3}{7}$	$\frac{7}{3}$	1	1	$\frac{7}{3}$
7	0	0	0	0	$\frac{4}{7}$	$\frac{7}{4}$	$\frac{2}{3}$	$\frac{3}{2}$	$\frac{21}{8}$
8	1	0	0	0	$\frac{3}{5}$	$\frac{5}{3}$	1	1	$\frac{5}{3}$
9	1	1	0	0	$\frac{2}{5}$	$\frac{5}{2}$	1	1	$\frac{5}{2}$
10	1	1	1	0	$\frac{2}{5}$	$\frac{5}{2}$	1	1	$\frac{5}{2}$
11	1	0	1	0	$\frac{3}{5}$	$\frac{5}{3}$	$\frac{1}{2}$	1	$\frac{10}{3}$
12	1	0	1	1	$\frac{3}{5}$	$\frac{5}{3}$	0	0	0

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



$$\begin{aligned} E(Y^{1,C=0}) &= \frac{1}{n} \sum_{i=1}^n w_i^{1C} \cdot y_i \cdot I(A_i = 1, C_i = 0) \\ &= \frac{1}{12} \left(0 + \frac{7}{3} + \frac{7}{3} + 0 + \frac{5}{2} \right) = 0.5972 \end{aligned}$$

$$\begin{aligned} E(Y^{0,C=0}) &= \frac{1}{n} \sum_{i=1}^n w_i^{0C} \cdot y_i \cdot I(A_i = 1, C_i = 0) \\ &= \frac{1}{12} \left(0 + 0 + \frac{7}{4} + 0 + 0 + 0 + \frac{10}{3} \right) = 0.424 \end{aligned}$$

D.h. $\hat{\psi}_{ATE} \approx 0.173 \rightarrow$ korrekt

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



```

m.w      <- glm(A~L, family=binomial)
weight   <- 1/predict(m.w, type="response")
weight[A==0] <- 1/(1-predict(m.w, type="response") [A==0])

m.w2 <- glm(A~1, family=binomial)
weight2      <- 1/predict(m.w2, type="response")
weight2[A==0] <- 1/(1-predict(m.w2, type="response") [A==0])

m.c <- glm(C~A*L*Y, family="binomial")
weight3      <- 0
weight3[C==0] <- 1/(1-predict(m.c, type="response") [C==0])
weight3[is.na(weight3)] <- 0

weight4 <- weight*weight3

# ATE
mean(Y*(A==1 & C==0)*weight4) -
mean(Y*(A==0 & C==0)*weight4)

# alternativ als MSM
lm(Y~A, weights=weight4, data=as.data.frame(cbind(Y,A)))

```

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

AIPTW-Schätzer [6]

Unter den Annahmen der Positivität, bedingten Austauschbarkeit und Konsistenz ist

$$\hat{\psi}_{\text{ATE, AIPTW}} = \frac{1}{n} \sum_{i=1}^n \left\{ \frac{I(A_i = 1)}{P(A_i = 1|L_i)} - \frac{I(A_i = 0)}{P(A_i = 0|L_i)} \times (Y_i - \hat{Y}_i) \right\} + \hat{\psi}_{\text{ATE, g-formula}}$$

ein doppelt robuster Schätzer für den Average Treatment Effect

ψ_{ATE} .



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

■ Der AIPTW-Schätzer ist doppelt robust (siehe z.B. [7]):

- 1 Sind sowohl das Modell für die Zielgröße² und die Behandlungszuweisung³ korrekt spezifiziert ist der Schätzer konsistent und asymptotisch effizient
- 2 Ist eines der beiden Modelle mis-spezifiziert, ist der Schätzer immer noch konsistent, jedoch nicht mehr asymptotisch effizient
- 3 sind beide Modelle mis-spezifiziert, so ist der Schätzer nicht mehr konsistent

■ Der Schätzer ist dennoch weiterhin volatil bei Positivitätsverletzungen

²verwendet für \hat{Y}_i und $\hat{\psi}_{ATE}$, g-formula

³also: $P(A|L)$



- Wenn das Regressionsmodell für Y korrekt spezifiziert ist, liefert die g-formula korrekte Ergebnisse
- In diesem Fall “reduziert sich der AIPTW-Schätzer zum g-formula Schätzer, der in einer endlichen Stichprobe nur von diesem zufällig auf Basis der geschätzten Residuen abweicht”
- Wenn das Regressionsmodell für Y mis-spezifiziert ist, wird der Schätzer bezüglich ψ_{ATE} korrigiert, über passende Gewichtung der Residuen

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

i	L	A	Y	$\frac{I(A_i=1)}{P(A_i=1 L_i)} - \frac{I(A_i=0)}{P(A_i=0 L_i)}$	\hat{Y}
1	0	0	0	?	?
2	0	0	1	?	?
3	0	0	0	?	?
4	0	1	0	?	?
5	0	1	1	?	?
6	0	1	1	?	?
7	0	0	0	?	?
8	1	0	0	?	?
9	1	1	0	?	?
10	1	1	1	?	?
11	1	0	1	?	?
12	1	0	1	?	?



Schätze $P(Y = 1|A, L)$ über logistische Regression:

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.099	1.155	-0.951	0.341
A	1.792	1.683	1.064	0.287
L	1.792	1.683	1.064	0.287
A:L	-2.485	2.517	-0.987	0.323

z.B: Schätze $P(Y = 1|A = 1, L = 1)$ über:

$$\frac{1}{1 + \exp(-[-1.099 + 1.792 \cdot 1 + 1.792 \cdot 1 - 2.485 \cdot 1 \cdot 1])} = 0.5$$

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



i	L	A	Y	$\frac{I(A_i=1)}{P(A_i=1 L_i)} - \frac{I(A_i=0)}{P(A_i=0 L_i)}$	\hat{Y}
1	0	0	0	?	0.25
2	0	0	1	?	0.25
3	0	0	0	?	0.25
4	0	1	0	?	0.67
5	0	1	1	?	0.67
6	0	1	1	?	0.67
7	0	0	0	?	0.25
8	1	0	0	?	0.67
9	1	1	0	?	0.50
10	1	1	1	?	0.50
11	1	0	1	?	0.67
12	1	0	1	?	0.67

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Mit

$$\begin{aligned} p_{11} &= P(A = 1|L = 1) &= \frac{2}{5} \\ p_{01} &= P(A = 0|L = 1) &= \frac{3}{5} \\ p_{10} &= P(A = 1|L = 0) &= \frac{3}{7} \\ p_{00} &= P(A = 0|L = 0) &= \frac{4}{7} \end{aligned}$$

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



i	L	A	Y	$\frac{I(A_i=1)}{P(A_i=1 L_i)} - \frac{I(A_i=0)}{P(A_i=0 L_i)}$	\hat{Y}
1	0	0	0	$-\frac{7}{4}$	0.25
2	0	0	1	$-\frac{7}{4}$	0.25
3	0	0	0	$-\frac{7}{4}$	0.25
4	0	1	0	$\frac{7}{3}$	0.67
5	0	1	1	$\frac{7}{3}$	0.67
6	0	1	1	$\frac{7}{3}$	0.67
7	0	0	0	$-\frac{7}{4}$	0.25
8	1	0	0	$-\frac{5}{3}$	0.67
9	1	1	0	$\frac{5}{2}$	0.50
10	1	1	1	$\frac{5}{2}$	0.50
11	1	0	1	$-\frac{5}{3}$	0.67
12	1	0	1	$-\frac{5}{3}$	0.67

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



$$\begin{aligned}
 \hat{\psi}_{\text{ATE, AIPTW}} &= \frac{1}{n} \sum_{i=1}^n \left\{ \frac{I(A_i = 1)}{P(A_i = 1|L_i)} - \frac{I(A_i = 0)}{P(A_i = 0|L_i)} \right. \\
 &\quad \left. \times (Y_i - \hat{Y}_i) \right\} + \underbrace{\hat{\psi}_{\text{ATE, g-formula}}}_{\text{Kapitel 5: 0.17359}} \\
 &= 0.17359 + \underbrace{\frac{1}{12} \left\{ -\frac{7}{4} \cdot (0 - 0.25) + \dots - \frac{5}{3}(1 - 0.67) \right\}}_{=0} \\
 &= 0.17359
 \end{aligned}$$

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

In R : korrektes Ergebnis, auch bei mis-spezifiziertem Modell



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

```
# 1) g-formula
m1 <- glm(Y~A*L, family=binomial)
# Setze A=1 und A=0
newdata1 <- as.data.frame(cbind(Y,A,L))
newdata1$A <- c(rep(1,12))
newdata0 <- as.data.frame(cbind(Y,A,L))
newdata0$A <- c(rep(0,12))
psi_gformula <- mean(predict(m1, type="response", newdata=newdata1)) - # E(Y1)
mean(predict(m1, type="response", newdata=newdata0)) # E(Y0)
```

2) Aktualisierung mit AIPTW

```
(est_AIPTW <- mean(((A==1)/predict(m.w, type="response")) - (A==0) /
  (1-predict(m.w, type="response")))
  * (Y-predict(m1, type="response")) + psi_gformula))
```

korrekt auch bei Mis-spezifizierung

```
est_AIPTW2 <- mean(((A==1)/predict(m.w2, type="response")) - (A==0) /
  (1-predict(m.w2, type="response")))
  * (Y-predict(m1, type="response")) + psi_gformula
```

Ergebnis beide Male: $\hat{\psi}_{\text{AIPTW}} = 0.174$



- gleiche Argumentation wie in Kapitel 5
- spezifiziere die Postinterventionsverteilung des DAGs für $A = a$ unter Verwendung der Markovbedingung
- Bestimme L mit Hilfe des Back-door Kriteriums
- Alternative Argumentation: "Pseudopopulation bei der es kein Confounding gibt"

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle


Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Beispiel:



Über Markovbedingung (Kapitel 2):

$$P(A, L, Y) = P(Y|A, L) \times P(A|L) \times P(L)$$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle


Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Beispiel:



Strukturgleichungen:

$$L = f_L(U_L)$$

$$A = f_A(L, U_A)$$

$$Y = f_Y(A, L, U_Y)$$



Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle
Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten


Augmented IPTW

Der graphische Ansatz

Literaturnachweise

Beispiel:

Streiche Pfeile, die in intervenierenden Knoten zeigen:



Strukturgleichungen:

$$L = f_L(U_L)$$

$$A = a$$

$$Y = f_Y(A, L, U_Y)$$



Verwendung der Markovbedingung sowie der Postinterventionsverteilung ergibt:

$$P(Y, L | do(A = a)) = P(Y | L, A = a) \times P(L)$$

und damit

$$\begin{aligned} P(Y | do(A = a)) &= \sum_l P(Y | L = l, A = a) \times P(L = l) \\ &= \sum_l P(Y | L = l, A = a) \times P(L = l) \times \frac{P(A = a | L = l)}{P(A = a | L = l)} \\ &= \frac{P(Y = 1 | A = a) \times P(A = a)}{P(A = a | L)} \\ &= \frac{P(Y = 1 | A = a) \times P(A = a)}{P(A = a | L)} \\ &= \frac{1}{N} \sum_{i=1}^N \frac{y_i \cdot I(A_i = a)}{P(A_i = a | L_i)} \end{aligned}$$

Horvitz-Thompson-Schätzer

IPTW

Stabilisierte Gewichte

Marginale strukturelle Modelle

Progressive Trunkierung

Positivität

Konfidenzintervalle

Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise



- [1] D. G. Horvitz and D. J. Thompson.
A generalization of sampling without replacement from a finite universe.
Journal of the American Statistical Association, 47(260):663–685, 1952.
- [2] M. Hernan and J. Robins.
Causal inference.
Chapman & Hall/CRC, Boca Raton, 2017.
- [3] M. A. Luque-Fernandez, G. Van Cutsem, E. Goemaere, K. Hilderbrand, M. Schomaker, N. Mantangana, S. Mathee, V. Dubula, N. Ford, M. A. Hernan, and A. Boule.
Effectiveness of patient adherence groups as a model of care for stable patients on antiretroviral therapy in Khayelitsha, Cape Town, South Africa.
Plos One, 8(2):e56088, 2013.
- [4] M. L. Petersen, K. E. Porter, S. Gruber, Y. Wang, and M. J. van der Laan.
Diagnosing and responding to violations in the positivity assumption.
Statistical Methods in Medical Research, 21(1):31–54, 2012.
- [5] P. C. Austin.
Variance estimation when using inverse probability of treatment weighting (iptw) with survival analysis.
Statistics in Medicine, 35(30):5642–5655, 2016.
- [6] J. M. Robins, A. Rotnitzky, and L. P. Zhao.
Estimation of regression-coefficients when some regressors are not always observed.
Journal of the American Statistical Association, 89(427):846–866, 1994.
- [7] A. N. Glynn and K. M. Quinn.
An introduction to the augmented inverse propensity weighted estimator.
Political Analysis, 18(1):36–56, 2010.

Horvitz-Thompson-
Schätzer

IPTW

Stabilisierte Gewichte
Marginale strukturelle
Modelle
Progressive Trunkierung
Positivität
Konfidenzintervalle
Fehlende Daten

Augmented IPTW

Der graphische Ansatz

Literaturnachweise